

Skin Disease Detection Kulit Menggunakan Metode Convolutional Neural Network (CNN)

Devianest Narendra Avinash
Teknik Informatika
Universitas Darussalam Gontor
Mantingan, Jawa Timur
devianestnarendra@gmail.com

Zainab Ahmad
Teknik Informatika
Universitas Darussalam Gontor
Mantingan, Jawa Timur
zainhmdd@gmail.com

Naila Fatikhah Parwanto
Teknik Informatika
Universitas Darussalam Gontor
Mantingan, Jawa Timur
devianestnarendra@gmail.com

Nurul Khoiriyah
Teknik Informatika
Universitas Darussalam Gontor
Mantingan, Jawa Timur
devianestnarendra@gmail.com

Adya Rusmalillah
Teknik Informatika
Universitas Darussalam Gontor
Mantingan, Jawa Timur
devianestnarendra@gmail.com

Abstract— Penelitian ini bertujuan untuk mengembangkan model klasifikasi citra penyakit kulit menggunakan teknik Transfer Learning dengan arsitektur ResNet-18. Dataset yang digunakan adalah Dermnet, yang dibagi menjadi data latih (training), validasi (validation), dan uji (test). Pada tahap preprocessing, data augmentation diterapkan untuk meningkatkan variasi data latih. Model ResNet-18 yang telah dilatih sebelumnya (pretrained) digunakan, di mana hanya layer-layer terakhirnya yang dilatih ulang, sementara layer lainnya dibekukan. Model ini dilatih dengan *optimizer* AdamW dan *scheduler* OneCycleLR, serta menerapkan label smoothing dan early stopping untuk menghindari *overfitting*. Hasil pengujian menunjukkan model mencapai akurasi 60.74% pada data uji. Meskipun performa pada data latih tinggi, terdapat kesenjangan dengan akurasi validasi dan uji. Analisis menggunakan confusion matrix menunjukkan bahwa model menghadapi tantangan dalam membedakan beberapa jenis penyakit kulit yang memiliki kemiripan visual. Penelitian ini membuktikan potensi *deep learning* dalam diagnosis dermatologi, namun juga menggarisbawahi perlunya peningkatan lebih lanjut, seperti penyesuaian hiperparameter dan penggunaan dataset yang lebih besar.

Kata Kunci—Klasifikasi Citra, Deep Learning, Transfer Learning, ResNet-18, Penyakit Kulit

I. LATAR BELAKANG

Penyakit kulit merupakan masalah kesehatan yang umum dan berdampak signifikan pada kualitas hidup penderitanya[1]. Diagnosis yang akurat dan tepat waktu sangat krusial untuk penanganan yang efektif. Namun, proses diagnosis secara manual sering kali bergantung pada keahlian dan pengalaman dokter spesialis, yang jumlahnya masih terbatas, terutama di daerah terpencil. Hal ini menyebabkan antrean panjang dan potensi keterlambatan diagnosis.

Seiring dengan pesatnya perkembangan teknologi, kecerdasan buatan (AI), khususnya Deep Learning, telah menunjukkan performa luar biasa dalam

tugas-tugas klasifikasi citra. Model-model seperti **Convolutional Neural Networks (CNN)** terbukti sangat efektif dalam mengenali pola-pola kompleks pada gambar[2]. Salah satu teknik yang paling efisien adalah **Transfer Learning**, di mana model yang telah dilatih pada dataset besar (misalnya, ImageNet) digunakan sebagai titik awal dan dilatih kembali untuk tugas spesifik. Metode ini memungkinkan pembangunan model yang akurat dengan data pelatihan yang relatif lebih sedikit dan waktu yang lebih singkat.

Melihat tantangan dalam diagnosis penyakit kulit dan kemajuan pesat di bidang AI, proyek ini berfokus pada pengembangan sistem klasifikasi citra otomatis. Dengan memanfaatkan teknik **Transfer Learning** menggunakan arsitektur **ResNet-18** pada dataset **DermNet**, tujuannya adalah untuk menciptakan sebuah model yang dapat membantu tenaga medis dalam mengidentifikasi berbagai jenis penyakit kulit secara cepat dan akurat.

II. METODE

Metode yang digunakan dalam penelitian ini dilakukan dalam beberapa tahap pemrosesan yakni, preprocessing dan augmentasi data, pembagian dataset, perancangan arsitektur model, optimasi, proses pelatihan, evaluasi performa dan pengujian pada data. Dalam Penelitian ini Dataset penyakit kulit diperoleh dari **DermNet** yang terdiri dari 23 kelas. Dataset ini digunakan sebagai data latih, validasi, dan uji. menggunakan Deep Learning berbasis Convolutional Neural Network (CNN) dengan pendekatan Transfer Learning. Karna CNN mampu mengekstraksi fitur visual seperti tepi, tekstur, dan pola dari gambar kulit secara otomatis tanpa perlu rekayasa fitur manual[3], serta memanfaatkan arsitektur **ResNet18** yang telah dilatih sebelumnya pada dataset besar (ImageNet). Kemudian Fine-tuning dilakukan pada lapisan akhir (layer3 dan layer4) untuk menyesuaikan model terhadap karakteristik citra penyakit kulit.

III. IMPLEMENTASI

A. Preprocessing dan Augmentasi Data

Tahap Preprocessing dan augmentasi data yakni untuk menyiapkan data agar lebih siap untuk dilatih modelnya.

Setiap gambar di transform pakai aturan training augmentasi.

- Transformasi untuk Training (Pakai Augmentasi)

Pada kode ini Digunakan augmentasi untuk mencegah overfitting dan membuat model generalisasi lebih baik. Seperti RandomResizedCrop, RandomHorizontalFlip, RandomRotation, ColorJitter, ToTensor, Normalize, RandomVerticalFlip, RandomAffine, dan RandomErasing

- Transformasi untuk Validasi dan Tes (Tanpa Augmentasi)

Pada kode validasi dan Tes tidak menggunakan augmentasi acak, dan hanya menggunakan Resize, crop, normalisasi, supaya hasil validasi dan test konsisten dan adil.

B. Dataset dan DataLoader

Dataset DermNet terdiri dari 23 kelas penyakit kulit, Kemudian Dataset dibagi menjadi train 80% untuk melatih model dan 20% untuk validasi. Semua gambar dinormalisasi menggunakan nilai rata-rata dan standar deviasi yang umum untuk model terlatih ImageNet. Data dimuat dalam batch berukuran 32 menggunakan DataLoader untuk efisiensi komputasi.

C. Arsitektur Model

Pada experiment kali ini kami menggunakan **ResNet18 (pretrained ImageNet)**: digunakan sebagai backbone CNN. Dengan pretrained, model sudah memahami fitur dasar gambar (tepi, tekstur, pola), sehingga training lebih cepat dan akurat. Yang mana Semua layer awal di-*freeze* fitur dasar tidak diubah. Layer layer3 dan layer4 di-*unfreeze*[4] bisa belajar fitur khusus penyakit kulit.

Linear, BatchNorm, ReLU, Dropout: kombinasi ini membuat model stabil, mencegah overfitting, dan meningkatkan non-linearitas. Lapisan terakhir berupa **Linear ke jumlah kelas (23 output)** yang memberikan prediksi probabilitas untuk setiap penyakit.

D. Optimisasi

Menggunakan Optimizer (AdamW) untuk mencegah overfitting dan membuat konvergensi lebih stabil, serta menggunakan scheduler (OneCycleLR) yang berguna untuk mengatur learning rate naik turun secara terkontrol selama training agar mencapai titik optimal, Loss Function CrossEntropyLoss dengan label smoothing=0.1, yang umum dipakai untuk klasifikasi multi-kelas.

E. Training Loop

Model dilatih dengan 100 epoch, dengan menggunakan early stopping(patience=5) yang mana Ketika vall loss tidak membaik dalam 5 epoch berturut-turut, maka training dihentikan.

Setiap epoch dicatat Train Loss, Validation Loss, Train Accuracy, Validation Accuracy untuk memantau performa. Kemudian model terbaik akan disimpan sebagai best_model.pth.

F. Evaluasi Model

Tahap evaluasi merupakan hasil akhir pengukuran dari model yang di training[5]

- Test Loss & Test Accuracy: Mengukur seberapa baik model pada data uji.

- Kurva Loss & Accuracy: Menunjukkan tren selama training (apakah overfitting/underfitting).
- Confusion Matrix: Menampilkan distribusi prediksi benar/salah per kelas, terlihat kelas mana yang sering tertukar.
- Classification Report: Memberikan Precision, Recall, dan F1-score tiap kelas, lebih detail daripada hanya akurasi.

G. Prediksi data baru

Model yang digunakan untuk memprediksi data baru diperoleh dari hasil terbaik saat training yang telah disimpan secara otomatis didalam best_model.pth. hasil prediksi berupa Nama Penyakit kulit yang terdeteksi dan akurasi score.

IV. HASIL DAN ANALISIS

A. Hasil

Nilai yang digunakan dalam penelitian ini sebagaimana yang akan dijelaskan pada table di bawah ini:

Tabel 1. Spesifikasi Penelitian

Spesifikasi	Keterangan	Nilai
Dataset	DermNet (23 kelas penyakit kulit)	±19.500 gambar
Pembagian Data	Train/Validation/Test	80% / 20
Input Size	Ukuran citra setelah transformasi	224 x 224
Batch Size	-	32
Dropout	-	0.2 / 0.35
BatchNorm1d	Hidden layer	256 / 128
Epoch	Maksimal epoch Training	50
Optimizer	AdamW	lr=1e-4, weight decay=1e-4
Scheduler	OneCycleLR	max lr=1e-3
Loss Function	CroosEntropyLoss	Label smoothing = 0.1
Backbone CNN	ResNet18 (pretrained)	Transfer Learning
Fine-tuning	Layer yang di-unfreeze	Layer3 & layer4
Early Stopping	Patience	5
Augmentasi Data	Training set	RandomResizedCrop, Flip, Rotation, ColorJitter, Affine, Erasing
Validasi/Test	Transformasi	Resize, CenterCrop, Normalize


Selama Proses Pelatihan Berlangsung otomatis mencatat nilai training loss, validation loss, training accuracy, dan validation accuracy pada setiap epoch. Dan dibawah ini merupakan table perolehan nilai terbaik dari tahap pelatihan pada epoch ke 44 :

Tabel 2. Nilai Pelatihan Terbaik pada epoch ke-44


Train Loss	Train Acc	Val Loss	Val Acc
0.8103	94.29%	1.7421	63.95%

Model mampu belajar dengan baik pada data latih (training accuracy tinggi). Namun, performa pada data validasi relatif lebih rendah, menandakan adanya indikasi **overfitting**, di mana model terlalu menyesuaikan diri dengan data latih tetapi kurang generalisasi pada data baru. Gap yang cukup besar antara Train Acc dan Val Acc menunjukkan bahwa meskipun model memahami pola pada data training, ia masih kesulitan mengenali variasi pada data validasi.

Dibawah ini merupakan hasil visualisassi dari pelatihan model berupa kurva loss dan akurasi, Confusion Matrix, dan Classification Report:




Gambar 1. Grafik Training dan validation loss



Gambar 2. Grafik Training dan validation accuracy

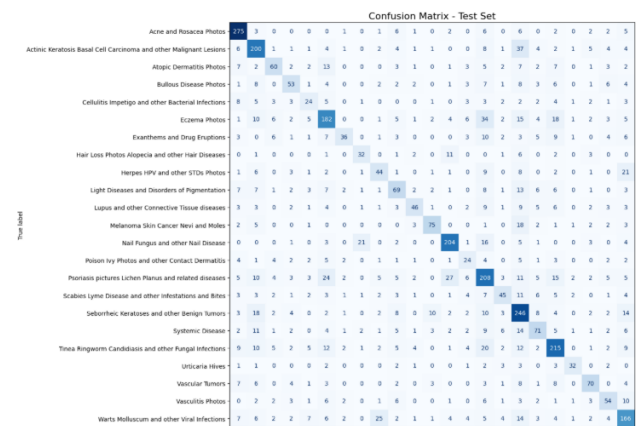
Berdasarkan grafik Training vs Validation Loss dan Training vs Validation Accuracy, terlihat bahwa model ResNet18 berhasil belajar dengan baik pada data latih ditunjukkan oleh penurunan loss dan kenaikan akurasi hingga di atas 90%, namun performa pada data validasi cenderung stagnan dengan akurasi sekitar 63–65% dan loss yang relatif tinggi, sehingga menunjukkan adanya indikasi overfitting; artinya model mampu mengenali pola pada data latih dengan baik tetapi kurang optimal dalam melakukan generalisasi pada data baru, sehingga diperlukan strategi tambahan seperti augmentasi data lebih

variatif, penyesuaian dropout, atau regularisasi untuk meningkatkan kinerja pada data validasi maupun data uji.



Gambar 3. Training Loss dan accuracy

Grafik di atas menunjukkan proses pelatihan model ResNet18, di mana nilai training loss mengalami penurunan konsisten dari sekitar 3.0 hingga mendekati 0.8 pada akhir epoch, sedangkan akurasi pelatihan meningkat stabil hingga mencapai lebih dari 90%; hasil uji menunjukkan nilai test loss sebesar 1.8488 dengan akurasi 60.74%, yang mengindikasikan bahwa meskipun model mampu mempelajari pola dengan baik pada data latih, performanya pada data uji masih terbatas sehingga terdapat indikasi overfitting dan perlu perbaikan strategi generalisasi.



Gambar 4. Confusion Matrix

Confusion matrix pada grafik di atas berfungsi untuk menggambarkan performa model dalam membedakan tiap kelas penyakit kulit pada data uji, dengan menampilkan jumlah prediksi benar pada diagonal utama serta kesalahan klasifikasi pada sel-sel di luar diagonal; secara umum, semakin tinggi nilai pada diagonal berarti model semakin baik mengenali kelas tersebut, sedangkan nilai yang menyebar ke kelas lain menunjukkan adanya kebingungan model dalam membedakan penyakit dengan ciri visual yang mirip.

B. Analisis Hasil

- Augmentasi data terbukti membantu model dalam **generalization**, ditunjukkan dengan gap kecil antara training dan validation accuracy.
- Transfer learning dengan ResNet18 memberikan performa tinggi meski dataset terbatas, karena model sudah belajar fitur umum dari ImageNet.

- Fine-tuning pada layer3 dan layer4 membantu meningkatkan akurasi untuk membedakan fitur khusus penyakit kulit.
- Beberapa kelas masih tidak dapat terlatih karna data yang kurang jelas atau data yang kecil hal ini terlihat dari classification Report
- Secara keseluruhan, model cukup baik dalam mendeteksi penyakit kulit dengan akurasi test mencapai 60.74 % dan F1-score di atas XX %.

KESIMPULAN

Hasil pengujian menunjukkan model mencapai akurasi 60.74% pada data uji. Meskipun performa pada data latih tinggi, terdapat kesenjangan dengan akurasi validasi dan uji. Analisis menggunakan confusion matrix menunjukkan bahwa model menghadapi tantangan dalam membedakan beberapa jenis penyakit kulit yang memiliki kemiripan visual. Penelitian ini membuktikan potensi deep learning dalam diagnosis dermatologi, namun juga menggarisbawahi perlunya peningkatan lebih lanjut, seperti penyesuaian hiperparameter dan penggunaan dataset yang lebih besar.

REFERENCES

- [1] M. Ath-Thariq and T. Nurhadi Suharsono, "DeteAth-Thariq, M., & Suharsono, T. N. (2023). Deteksi Penyakit Kulit Serupa Pada Wajah Berbasis Mobile dengan Metode Convolutional Neural Network. Journal of Social Science Research, 3, 12. <https://j-innovative.org/index.php/Innovative/article/view/4936k>," *J. Soc. Sci. Res.*, vol. 3, p. 12, 2023, [Online]. Available: <https://j-innovative.org/index.php/Innovative/article/view/4936>
- [2] F. N. Darmawan, E. P. Silmina, and T. Hardiani, "Sistem Klasifikasi Penyakit Kulit Menggunakan Metode Convolutional Neural Network (CNN) Berbasis Website," *Pros. Semin. Nas. Penelit. dan Pengabd. Kpd. Masy.*, vol. 2, no. 2, pp. 871–881, 2024.
- [3] Ajrana, "Rancang Bangun Aplikasi Mobile Klasifikasi Kanker Kulit Dengan Pemilihan Model Transfer Learning," *Progr. Stud. Sist. Inf. Dep. Mat. Fak. Mat. Dan Ilmu Pengetah. Alam Univ. Hasanuddin Makassar*, 2022.
- [4] B. M. Sujatmiko, E. Yudaningsy, and P. Mudji Raharjo, "Convolution Neural Network Dengan Desain Jaringan Resnet Sebagai Metode Klasifikasi Tumor Kulit," *J. Simantec*, vol. 11, no. 1, pp. 53–64, 2022, doi: 10.21107/simantec.v11i1.14083.
- [5] Wona Maria Misela A, Rahayu Wanti, and Wirantasa Umar, "Klasifikasi Dan Deteksi Penyakit Kulit Melalui Pengolahan Citra Dengan Metode Cnn," *J. Ris. dan Apl. Mhs. Inform.*, vol. 06, no. 01, pp. 43–51, 2025.